

PJ-AG4 项目中期报告

LLM 驱动的高端 GPU 算力现货市场多 Agent 博弈仿真

易俊融

May 5, 2026

Abstract

本项目构建一个面向高端 GPU 算力现货与供应链分销市场的多 Agent 动态博弈仿真系统。市场中包含规模主导型 Hyperscaler、稳健交付型 PremiumCloud 和现货套利型 SpotBroker 三类异质 Agent。每个 Agent 在有限历史信息下进行需求预测、报价和新增供给决策，环境根据价格、品牌、声誉、库存、缺货和同行算力拆借机制完成统一结算。中期阶段已经完成可复现仿真内核、LLM 决策后端、启发式回退策略、CSV/PDF/HTML 输出和量化实验工具。本报告以本地 OpenAI-compatible 端点接入的 LLM 20 轮实验为主，结果显示 LLM 策略在 seed=7 的实验中达到 0.9963 的市场履约率和 1010.34 的市场总利润，相比同设置启发式基线在总利润上更高，但伴随 Hyperscaler 的轻微缺货和一次 default 事件。实验表明，声誉约束、价格纪律和库存控制共同塑造了 Agent 间的收益分化，项目已经具备进入最终实验扩展和论文式分析的基础。

关键词：多 Agent 仿真；大语言模型；市场博弈；GPU 算力；声誉机制；供应链

1 引言

高端 GPU 算力市场同时具有金融现货市场、供应链分销市场和云资源调度市场的特征。一方面，训练与推理需求受到大模型发布、企业采购周期、算力集群扩容和外部冲击影响，呈现明显的时间波动；另一方面，高端 GPU 节点又具有重资产属性，未售出或未出租的算力会持续产生托管、电力、资金占用和技术折旧成本。供应商不仅需要制定价格，还需要决定备货规模、履约优先级和同行间临时拆借策略。

本项目以该场景为背景，研究由 LLM Agent 参与的重复市场博弈。与静态定价模型不同，本项目关注三个问题：第一，不同经营风格的 Agent 在重复竞争中的收益差异如何形成；第二，有限理性和带噪声需求观察如何影响 Agent 的预测与库存决策；第三，声誉机制能否约束低价倾销、违约和拒绝合作等短期行为。

中期阶段的目标不是完成真实市场预测系统，而是完成一个规则透明、可复现、可替换策略后端的实验平台。当前项目已经实现从场景设计到可运行系统的闭环，并能够使用本地 OpenAI-compatible LLM 端点直接生成 Agent 决策。本报告总结系统建模、代码实现、LLM 实验结果、当前不足和后续计划。

2 市场模型与机制设计

2.1 Agent 角色设定

市场中包含三个独立决策者，分别代表高端 GPU 算力市场中的三类典型经营主体。表 1 总结了其角色差异。

Table 1: 三类市场参与者设定

Agent	角色定位	决策倾向	主要风险
Hyperscaler	规模主导型供应商	低价、大容量、争夺份额	价格战与利润侵蚀
PremiumCloud	稳健交付型云服务商	高声誉、SLA、价格纪律	高价下份额流失
SpotBroker	现货套利型经纪商	灵活调价、轻库存、高周转	缺货与长期声誉不足

每一轮 t 中，Agent i 选择报价 $p_{i,t}$ 和新增可交付节点数 $q_{i,t}$ 。轮初库存为 $I_{i,t}$ ，因此本轮可用供给为

$$A_{i,t} = I_{i,t} + q_{i,t}.$$

2.2 动态需求与有限理性观察

市场总需求由趋势、季节项、冲击项和自回归噪声构成：

$$D_t = \max\{D_{\min}, b + gt + S_t + H_t + \epsilon_t\}.$$

其中 b 为基准需求， g 为趋势增长率， S_t 为周期项， H_t 为外部冲击， ϵ_t 为 AR 噪声。Agent 不能直接观察完整真实需求，而是接收带噪声的观测需求和有限窗口历史。这一设计用于刻画现实市场中的信息不完全和有限理性。

2.3 需求分配、拆借与收益结算

需求分配采用 logit 型吸引力机制。Agent 的市场吸引力为

$$a_{i,t} = b_i + \beta_R R_{i,t} - \beta_p p_{i,t},$$

其中 b_i 是品牌强度， $R_{i,t}$ 是声誉， β_R 和 β_p 分别表示声誉权重和价格敏感度。需求份额为

$$s_{i,t} = \frac{\exp(a_{i,t})}{\sum_j \exp(a_{j,t})}, \quad y_{i,t} = D_t s_{i,t}.$$

若 $A_{i,t} < y_{i,t}$ ，Agent 会出现初始缺货；若其他 Agent 存在富余供给，则环境触发同行算力拆借。拆借意愿由缺货方合作声誉、供给方自身负载和缺货方上一轮是否倾销共同决定。最终成交、缺货、库存折旧和收益由统一环境结算，Agent 不直接修改环境状态。

收益函数综合客户收入、拆借收入与成本、采购成本、库存持有成本、技术折旧、SLA 违约惩罚和调价菜单成本：

$$\begin{aligned} \pi_{i,t} = & p_{i,t} x_{i,t} + \sum_{k \neq i} w_{i \rightarrow k, t}^{tr} m_{i \rightarrow k, t} - \sum_{j \neq i} w_{j \rightarrow i, t}^{tr} m_{j \rightarrow i, t} \\ & - c_i q_{i,t} - \gamma_i q_{i,t}^2 - h_i I_{i,t+1} - \psi_i \text{obso}_{i,t} - \lambda_i \text{short}_{i,t} - \chi_i |p_{i,t} - p_{i,t-1}|. \end{aligned}$$

声誉被拆分为交付声誉、定价声誉和合作声誉，再按权重聚合。该机制使价格战、违约和拒绝合作都会影响后续市场份额或拆借机会。

3 系统实现

3.1 代码结构

项目目前已经实现为本地可运行的 Python 包，核心目录结构如下：

```
src/pj_ag4/
  config.py          仿真、市场和 Agent 参数
  timeseries.py      动态需求生成
  environment.py     市场结算、拆借、库存、声誉和收益更新
  agents.py         启发式 Agent 与 LLM Agent 决策链
  core/runtime.py    逐轮仿真编排
  data/observation.py 有限理性市场观察构造
  dashboard.py      HTML dashboard 渲染
  web.py           localhost 交互式服务
quant/
  common.py        批量实验运行接口
  metrics.py       收益、风险和履约指标
  reporting.py     CSV 与 Markdown 报告导出
```

运行流程为：需求生成器产生本轮需求；ObservationBuilder 为每个 Agent 构造观察；Agent 输出预测、价格和新增供给；MarketEnvironment 统一结算；结果写入 CSV 并生成图表和 dashboard。

3.2 Agent 决策链

Agent 决策已拆分为四阶段：

Forecaster → Pricer → Allocator → RiskGate.

Forecaster 负责需求预测，Pricer 负责报价，Allocator 负责新增供给，RiskGate 负责价格边界、库存暴露和声誉风险约束。三类 Agent 的阶段风格见表 2。

Table 2: Agent 阶段式决策风格

Agent	Forecaster	Pricer	Allocator	RiskGate
Hyperscaler	momentum_chaser	share_grabber	capacity_expander	growth_tolerant
PremiumCloud	signal_smoother	premium_keeper	buffered_allocator	sla_guard
SpotBroker	volatility_reader	spread_hunter	inventory_light	inventory_guard

3.3 LLM 后端

LLM 模式通过 OpenAI-compatible API 接入。每个 Agent 接收包含角色身份、阶段风格、近期需求、价格历史、声誉历史、库存、上一轮利润、缺货情况和合法动作范围的 JSON prompt，

并返回：

```
{forecast_demand, price, quantity}.
```

若模型输出格式异常或调用失败，系统使用对应角色的 heuristic action 作为 fallback，以保证仿真连续性。中期实验使用本地端点 `http://127.0.0.1:8045/v1`，模型名为 `gemini-3-flash`。

4 LLM 实验设计

4.1 实验设置

本报告以 LLM 直接接入实验作为主实验，使用固定随机种子 `seed=7`，运行 20 轮。为判断 LLM 策略相对启发式策略的差异，同时运行同 `seed`、同轮数的 heuristic baseline。实验命令如下：

```
python3 -m pj_ag4.cli \
  --agent-mode llm \
  --llm-base-url http://127.0.0.1:8045/v1 \
  --llm-model gemini-3-flash \
  --llm-api-key local-dev-key \
  --rounds 20 \
  --seed 7 \
  --output-dir reports/midterm/llm_run_20

python3 -m pj_ag4.cli \
  --agent-mode heuristic \
  --rounds 20 \
  --seed 7 \
  --output-dir reports/midterm/heuristic_run_20
```

LLM 主实验共生成 60 行 Agent-round 级结算记录，并输出 CSV 结果、PDF 分析图和 HTML dashboard。

4.2 评价指标

报告使用以下指标：

- 市场履约率：总实现交付量除以总真实需求；
- 市场总利润：所有 Agent、所有轮次利润之和；
- Agent 累计利润：单个 Agent 20 轮累计收益；
- 平均服务率：单个 Agent 的平均需求满足比例；
- 平均声誉：单个 Agent 每轮末总声誉平均值；
- 缺货、dump 和 default 事件：衡量履约风险与低价竞争行为。

5 实验结果与分析

5.1 LLM 主实验总体结果

LLM 20 轮实验的市场总需求为 3758.00，总实现交付为 3743.93，市场履约率为 0.9963，市场总利润为 1010.34。表 3 给出了 Agent 层面的主要结果。

Table 3: LLM 主实验 Agent 结果 (20 轮, seed=7)

Agent	累计利润	平均服务率	平均声誉	总缺货	Dump	Default	平均价格	终局库存
Hyperscaler	-1855.98	0.9940	0.6176	13.79	20	1	4.000	14.47
PremiumCloud	1566.41	1.0000	0.8628	0.00	0	0	6.940	4.63
SpotBroker	1299.92	0.9997	0.8237	0.28	0	0	5.580	11.07

结果显示，LLM Agent 形成了清晰的经营分化。Hyperscaler 维持最低价格并持续触发 dump 标记，市场份额和服务率较高，但利润显著为负；PremiumCloud 维持高价格和高声誉，获得最高累计利润；SpotBroker 以中等偏高价格和较轻库存获得次高利润，并保持接近完全履约。




Figure 1: LLM 策略下三个 Agent 的累计收益演化

图 1 显示，Hyperscaler 在早期即进入负收益区间，且亏损随轮次持续扩大；PremiumCloud 和 SpotBroker 则稳定积累正收益。这一结果说明，价格战并不必然带来长期优势，声誉和价格纪律在重复博弈中能够转化为稳定收益。

5.2 履约、价格与状态演化




Figure 2: LLM 策略下市场需求、实现交付与平均价格

图 2 表明，LLM 策略下市场整体履约率维持在较高水平，未履约缺口主要集中在少数轮次。平均价格保持在较高区间，说明 LLM 并未简单地将所有 Agent 推向低价竞争，而是保留了角色差异。




Figure 3: LLM 策略下库存、声誉和服务率动态

图 3 进一步展示了库存与声誉的动态。PremiumCloud 的声誉最稳，SpotBroker 保持中高声誉，Hyperscaler 则因持续低价和一次 default 事件受到声誉约束。库存层面，三者均未出现严重终局积压，这说明 RiskGate 和环境中的库存折旧成本对供给决策产生了约束。

5.3 LLM 与启发式基线对照

同 seed、同 20 轮设置下，LLM 策略与启发式策略的市场级结果见表 4。

Table 4: LLM 与启发式基线对照（20 轮，seed=7）

策略	市场总利润	履约率	平均声誉	总缺货
Heuristic	763.91	0.9989	0.7836	3.95
LLM	1010.34	0.9963	0.7680	14.07




Figure 4: LLM 与启发式基线的市场级指标对照

从表 4 和图 4 可以看到，LLM 策略的市场总利润高于 heuristic，但履约率略低、总缺货更高。这说明 LLM 决策在当前设置下更倾向于维持高价值订单和价格纪律，而不是机械追求最高履约率。该结果具有一定研究价值：LLM Agent 并非简单复制启发式规则，而是在角色 prompt、市场观察和风险约束共同作用下形成了不同的利润-服务权衡。

需要注意的是，当前 LLM 对照只完成了单 seed 实验。由于本地模型端点推理耗时较长，多 seed 长跑将在后续阶段继续补充，以判断该差异是否稳健。

6 当前完成度

截至中期，项目已经完成以下工作：

1. 完成高端 GPU 算力现货与供应链博弈场景设计；
2. 实现动态需求生成、需求分配、同行拆借、库存折旧、SLA 罚金和声誉更新；
3. 实现三类异质 Agent，并拆分为 Forecaster、Pricer、Allocator 和 RiskGate 四阶段；
4. 接入 OpenAI-compatible LLM 后端，并实现 JSON 输出解析和 heuristic fallback；
5. 实现 CLI、本地 dashboard、CSV 输出、PDF 图表和 HTML 可视化；
6. 实现 quant/ 实验层，用于 benchmark、敏感性分析和报告导出；
7. 完成 LLM 20 轮主实验和同 seed 启发式对照实验；
8. 当前自动化测试集通过，共 27 个测试。

从中期验收角度看，项目已经具备可运行、可复现、可解释、可视化和可扩展的核心能力。尤其是 LLM 模式已经不再停留于接口设计，而是能够完整参与多轮市场决策并产生可分析结果。

7 问题与后续计划

当前主要问题包括：

- LLM 长轮次实验耗时较高，受本地 OpenAI-compatible 端点吞吐影响明显；
- 当前 LLM 结果仍以单 seed 为主，多 seed 稳健性尚未充分验证；
- Agent 阶段逻辑虽已拆分，但实现仍集中在 `agents.py`，后续应进一步模块化；
- 目前对 LLM 决策理由的记录还不够丰富，后续可保存每轮 prompt、raw response 和 fallback 标记；
- 还需要系统完成 ablation 实验，例如关闭声誉机制、关闭拆借机制或改变库存折旧强度。

后续计划分为三步。第一，扩展 LLM 实验规模，至少完成多 seed、不同需求冲击强度和不同声誉权重下的 LLM 对照。第二，完善报告层，自动生成论文所需的表格、图和统计摘要。第三，继续重构 Agent 模块，将阶段策略、LLM provider、prompt 模板和风险门控拆为更清晰的文件结构。

8 结论

本项目中期阶段已经完成从市场博弈设想到可运行 LLM 多 Agent 仿真平台的转化。系统能够模拟高端 GPU 算力市场中的动态需求、价格竞争、库存折旧、SLA 缺货、同行拆借和声誉演化，并能使用本地 LLM 后端直接生成 Agent 决策。

LLM 20 轮实验表明，三个 Agent 在相同市场环境中形成了明显分化：Hyperscaler 因持续低价竞争出现负利润，PremiumCloud 借助高声誉和价格纪律获得最高收益，SpotBroker 以灵活策略获得稳健正收益。与启发式基线相比，LLM 策略获得更高市场总利润，但承担了略高缺货风险。这说明 LLM Agent 在重复博弈中能够呈现不同于固定启发式规则的权衡行为，为后续研究 LLM 决策风格、声誉机制和市场稳定性提供了实验基础。

参考文献

1. Russell S., Norvig P. Artificial Intelligence: A Modern Approach. Pearson, 2021.
2. Shoham Y., Leyton-Brown K. Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations. Cambridge University Press, 2008.
3. Sutton R. S., Barto A. G. Reinforcement Learning: An Introduction. MIT Press, 2018.
4. Brown T. et al. Language Models are Few-Shot Learners. NeurIPS, 2020.
5. OpenAI. OpenAI-compatible Chat Completions API documentation.